

# Gestión de sentencias: Proyecto de programación

Daniel Franco Barranco  
Iván Matellanes Pastoriza  
Asier Mujika Aramendia

Estructuras de Datos y Algoritmos  
Grado en Ingeniería Informática

Diciembre de 2012

# Índice

<b>1. Resumen</b>	<b>3</b>
<b>2. Introducción</b>	
2.1. Objetivos	3
2.2. Metodología	4
<b>3. Versión 0</b>	
3.1. Estructura	5
3.2. Implementación	7
3.3. Análisis de complejidad	8
3.4. Tiempos de ejecución	12
<b>4. Versión 1</b>	<b>13</b>
<b>5. Versión 2</b>	<b>14</b>
<b>6. Actas de las reuniones</b>	<b>15</b>
<b>7. Anexos</b>	<b>17</b>

# 1. Resumen

*Aquí debe presentarse un resumen de todo el trabajo, que no debe superar la media página (más o menos). Debe explicarse en qué consiste el trabajo presentado, qué partes tiene y de qué trata cada*

## 2. Introducción

*En esta sección debe explicarse el escenario del trabajo. Se presentarán también los objetivos del mismo: enunciado del problema a resolver y el alcance de funcionalidad de la implementación que se ha desarrollado.*

### 2.1 Objetivos

La idea principal del proyecto que se nos presenta en esta asignatura es la de gestionar sentencias simples, que tendrá la forma de **sujeto propiedad objeto**. Para realizar este cometido, las sentencias han de agruparse en almacenes sobre los que se definen una serie de operaciones a implementar. A continuación se listan algunos ejemplos de estas operaciones:

- Obtener las sentencias de un almacén con un sujeto determinado.
- Obtener una colección ordenada de todas las sentencias del almacén.
- Dar una colección de entidades que son sujetos en varios almacenes distintos.
- Cargar sentencias a un almacén desde un fichero de texto.

Algunas de las propiedades pueden recibir un tratamiento especial, como es el caso de **es** y **subClaseDe**, y en base a este se piden ciertas operaciones, entre las que se incluyen: las clases que son superclases de otra, los profesores que trabajan para un determinado departamento, etc.

Desde el primer momento, la intención de los tres componentes del grupo ha sido realizar la estructuración e implementación del proyecto de la forma más eficiente posible en base a las estructuras de datos que conocemos. De este modo, hemos pretendido escribir código limpio, correcto y eficaz para la versión inicial o versión 0, y así evitar futuras reestructuraciones o amplias modificaciones en el código. Las ideas planteadas se exponen más detalladamente en el siguiente apartado.

Éramos conscientes de que según avanzara el curso sería imprescindible realizar ajustes para hacer el programa más competitivo, pero nuestra intención era que los inevitables ajustes no supusieran replantear toda la estructura inicial.

## 2.2 Metodología

Realizar un trabajo en equipo puede ser una ardua tarea si no se administra debidamente. Es por ello que se decidió ir repartiendo la tarea según se avanzaba en el desarrollo del proyecto, procurando no solapar el trabajo de unos y otros y equilibrar la carga de trabajo de cada miembro del grupo.

Con objeto de facilitar el trabajo en equipo y agilizar la tarea de compartir el código del proyecto, se decidió abrir un repositorio común on-line del sistema de control de versiones *Git*. Esto nos ha facilitado la tarea de comunicar los cambios que se van realizando en el proyecto mediante *commits* y nos ha permitido a todos trabajar sobre el mismo código. Cabe decir que el repositorio es de acceso público y se encuentra en la siguiente dirección:

<https://github.com/Sulley38/ProyectoEDA>

### 3. Versión 0

*Puesto que se trata de dejar constancia de todo el trabajo realizado durante el curso, es interesante plasmar en distintas secciones los estados principales por los que ha ido pasando la aplicación desarrollada. Así, podemos redactar una sección, que corresponderá con una nueva versión, por cada organización fundamental de los datos a procesar (diseño de datos) y sus correspondientes implementaciones de métodos que hayamos alcanzado con esa versión.*

*Se explicarán brevemente las decisiones de diseño de las estructuras de datos seleccionadas para resolver los problemas que se aborden inicialmente y se enumerarán los métodos que se han implementado.*

*Para cada método se indicará lo que hace (especificación) y, si es relevante, se dará también una breve explicación de cómo lo hace. Cada método irá acompañado de su clasificación en complejidad algorítmica y de una justificación de esa clasificación.*

*Además, para los métodos más importantes, se realizarán pruebas de ejecución sobre datos de entrada de distintos tamaños para registrar el tiempo necesitado por esos métodos y se presentarán las tablas de resultados del modo más conveniente para su interpretación.*

*El código fuente de los programas implementados puede agruparse en un anexo que se presenta en una sección creada al efecto al final de la memoria.*

#### 3.1 Estructura

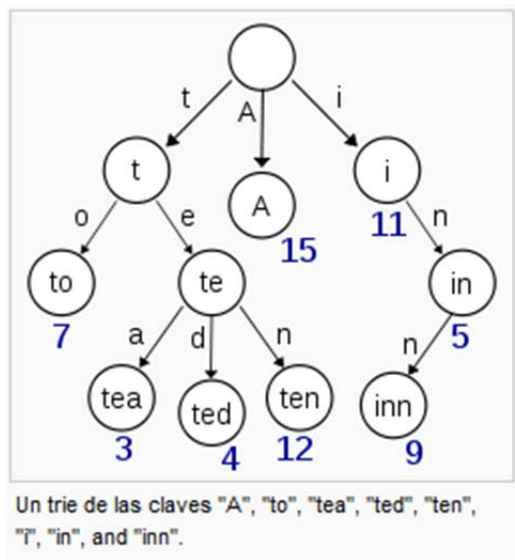
La idea básica con la que comenzamos a abordar este proyecto se detalla a continuación.

En primer lugar, para contener las relaciones entre sentencias, en lugar de utilizar *arrays* simples o listas enlazadas (que hubiera sido la idea más sencilla a primera vista), decidimos representar todas las sentencias utilizando un grafo dirigido ponderado en el que los nodos serían los sujetos y objetos, y el peso de las aristas estaría asociado a las propiedades de las sentencias. Se le asigna a cada entidad (sujeto, objeto y propiedad) un valor numérico para posteriormente administrar todo con una lista de adyacencia.



**Imagen 1.** Representación del grafo.

Para relacionar el *string* de una entidad con su valor numérico correspondiente utilizamos un árbol de prefijos (trie).




**Imagen 2.** Ejemplo de trie (Wikipedia).

Como en el ejemplo se puede observar, para obtener el valor de una palabra recorreremos el árbol siguiendo el camino del *string* letra a letra. En nuestro caso, haremos el mismo árbol, guardando sus características pero teniendo en cuenta que si el nodo no es el final de una palabra, tendrá el valor por defecto de -1. El valor que se indica en azul es el correspondiente al *string* que termina en ese nodo.

En el sentido contrario, si queremos conocer a qué *string* pertenece un índice dado, se accede a un *array* de *strings* en la posición del índice, que devuelve el *string* correspondiente.

Esto sería un ejemplo completo de la estructura de “codificación/descodificación”:

1	2	3	4	5	
aa	bb	ba	a	ab	....



**Imagen 3.** Conversión *int*->*string* y *string*->*int*.

### 3.2 Implementación

Con todos los datos ya en forma numérica, es turno de ver la implementación del grafo a nivel de código. En primer lugar, se pensó describirlo utilizando una matriz de adyacencia como la que se muestra en el siguiente ejemplo:

**Estudiante2013 = 1**  
**Matriculado = 3**  
**En upv-ehu = 2**

Como se puede observar en el ejemplo se pondría en cada casilla un valor '-1' en caso de no haber relación entre los sujetos y objetos. Y en el caso de que la hubiese se pondría el valor de la propiedad que les une.

Objetos			
Sujetos	...	En upv-ehu	...
Estudiante2013	-1	3	-1
...	-1	-1	-1
...	-1	-1	-1

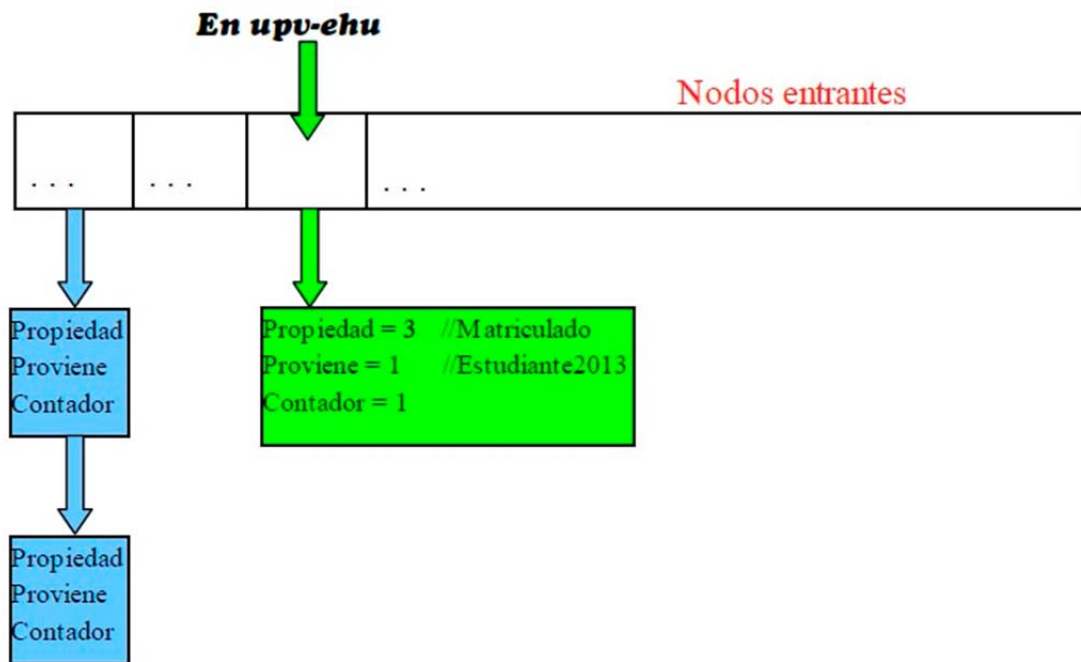
*Imagen 4. Representación con matriz de adyacencia.*

Esta forma de organizar los objetos, sujetos y propiedades no resultó ser como creíamos de efectiva al tener que hacer una matriz de adyacencia con gran cantidad de filas y columnas y mucha memoria desaprovechada con valores -1. Por lo tanto, para esta tarea en la 3ª reunión decidimos utilizar otra estructura.

La nueva idea se basó en el concepto de lista de adyacencia. Hemos usado una lista (implementada como array) para las aristas de entrada a un nodo y otra para las salidas. Cada posición del array se corresponde con uno de los sujetos u objetos, siguiendo el valor que le otorgamos al introducirlo en el trie. Los valores se dan de forma secuencial, según el orden en que se leen desde el fichero de sentencias, y se han utilizado tries distintos para sujetos/objetos y propiedades. Cada posición del array tiene un apuntador al comienzo de una lista enlazada, cuyos elementos contienen 3 variables para darnos la siguiente información:

- Propiedad: nos da la propiedad que entra/sale del nodo en el que estamos.

- Objetivo: nos da la información del nodo al que va/del cual proviene.
- Repeticiones: nos da la información de cuantas veces está repetida la arista que entra/sale a este nodo.



*Imagen 5. Representación con lista de adyacencia.*

La misma idea que se muestra en la imagen 5 se aplica para la segunda lista de adyacencia, pero esta vez indicando las aristas que salen de cada nodo.

### 3.3 Análisis de complejidad

Las estructuras de “codificación/descodificación” permiten realizar ambas operaciones asociativas en un tiempo mínimo, como se puede apreciar en el análisis de complejidad de los métodos del árbol de prefijos:

Insertar un string en el trie:

```
public int insertar( String s, int valor ) { ... }
```



Avanza por las ramas del trie siguiendo el camino que dictan los caracteres de s. Si faltan nodos, se añaden y al último se le da el valor del parámetro. Si ya existen, se devuelve el valor del último nodo.

- *Tamaño de la entrada:* longitud de s  $\equiv m$
- *Operación elemental:* asignación
- *Número de operaciones elementales en el caso peor:*

$$2 + \sum_{i=0}^{m-1} 2 + 2 = 2 + 2(m - 1 + 1) + 2 = 2m + 4$$

$$O(m)$$

Obtener el valor numérico de un string del trie:

```
public int obtenerValor( String s ) { ... }
```

Avanza por las ramas del trie siguiendo el camino que dictan los caracteres de s. Devuelve el valor del último nodo visitado. Si falta algún nodo, la palabra no está en el trie y devuelve -1.

- *Tamaño de la entrada:* longitud de s  $\equiv m$
- *Operación elemental:* asignación
- *Número de operaciones elementales en el caso peor:*

$$1 + \sum_{i=0}^{m-1} 1 = 1 + m - 1 + 1 = m + 1$$

$$O(m)$$

Usando estos métodos, las cuatro primeras operaciones que se piden en el enunciado de la práctica resultan de un orden de complejidad bastante asequible:

1) Colección de sentencias del almacén que tienen un sujeto determinado:

```
public ListaEnlazada<String> sentenciasPorSujeto( String sujeto ) { ... }
```

Obtiene el valor *int* a partir del parámetro sujeto, y recorre la lista enlazada que se encuentra en la posición obtenida del array *nodosSalientes*, devolviendo todas las sentencias que indican los elementos de la lista.

- *Tamaño de la entrada:* longitud de sujeto  $\equiv m$ , número de aristas salientes del nodo  $\equiv n$ , número de veces que aparece repetida una arista determinada  $\equiv k$
- *Operación elemental:* asignación
- *Número de operaciones elementales en el caso peor:*

$$\begin{aligned}
2 + \sum_{i=0}^{m-1} 1 + 2 + \sum_{it=1}^n \left( 1 + \sum_{i=0}^{k-1} 3 \right) &= 2 + (m - 1 + 1) + 2 + \sum_{it=1}^n (1 + 3(k - 1 + 1)) \\
&= 4 + m + \sum_{it=1}^n 3k + \sum_{it=1}^n 1 = 4 + m + 3k(n - 1 + 1) + (n - 1 + 1) \\
&= 4 + m + (3k + 1)n \\
&\quad O(m + kn)
\end{aligned}$$

2) Colección de sentencias distintas del almacén que tienen un sujeto determinado:

```
public ListaEnlazada<String> sentenciasDistintasPorSujeto( String sujeto )
{ ... }
```

Realiza las mismas operaciones que la función anterior, pero devolviendo cada sentencia una única vez.

- *Tamaño de la entrada:* longitud de sujeto  $\equiv m$ , número de aristas salientes del nodo  $\equiv n$
- *Operación elemental:* asignación
- *Número de operaciones elementales en el caso peor:*

$$\begin{aligned}
2 + \sum_{i=0}^{m-1} 1 + 2 + \sum_{it=1}^n (1 + 3) &= 2 + (m - 1 + 1) + 2 + 4(n - 1 + 1) = 4 + m + 4n \\
&\quad O(m + n)
\end{aligned}$$

3) Colección de propiedades distintas que aparecen en las sentencias del almacén:

```
public ListaArray<String> propiedadesDistintas() { ... }
```

Devuelve el array de propiedades.

- *Tamaño de la entrada:* -
- *Operación elemental:* retorno
- *Número de operaciones elementales en el caso peor:* 1

$$O(1)$$

4) Colección de entidades distintas que son sujeto de alguna sentencia y también son objeto de alguna sentencia de ese almacén:

```
public ListaEnlazada<String> entidadesSujetoObjeto() { ... }
```

Recorre las dos listas de adyacencia, y en caso de que en una misma posición ninguna esté vacía (un nodo tenga aristas entrantes y salientes), devuelve la entidad correspondiente a esa posición.

- *Tamaño de la entrada*: número de sujetos y objetos  $\equiv n$
- *Operación elemental*: asignación
- *Número de operaciones elementales en el caso peor*:

$$1 + \sum_{i=0}^{n-1} 3 = 1 + 3(n - 1 + 1) = 1 + 3n$$

$$O(n)$$

El método más costoso y esencial de nuestra implementación es, sin duda, la constructora de la clase *Almacén*. Dada su importancia, se detalla el análisis del algoritmo a continuación:

```
public Almacen( String nombreDeArchivo ) { ... }
```

Inicializa los atributos de clase, lee las sentencias del fichero especificado y las inserta en las diferentes estructuras de datos del modo en que se ha explicado en el apartado anterior.

- *Tamaño de la entrada*: número de sentencias en el fichero  $\equiv n$ , longitud del sujeto  $\equiv m_1$ , longitud de la propiedad  $\equiv m_2$ , longitud el objeto  $\equiv m_3$
- *Operación elemental*: asignación
- *Número de operaciones elementales en el caso peor*:

$$\begin{aligned} 12 + \sum_{i=1}^n & \left( 4 + m_1 + 11 + m_2 + 5 + m_3 + 11 + 2 \left( 3 + \sum_{it=1}^i 3 + 3 \right) \right) \\ &= 12 + \sum_{i=1}^n \left( 31 + m_1 + m_2 + m_3 + 2(6 + 3(i - 1 + 1)) \right) \\ &= 12 + \sum_{i=1}^n (43 + m_1 + m_2 + m_3 + 6i) \\ &= 12 + (43 + m_1 + m_2 + m_3)n + 6 \left( \frac{1+n}{2} n \right) \\ &= 12 + (46 + m_1 + m_2 + m_3)n + 3n^2 \end{aligned}$$

$$O(n^2)$$

La complejidad de las operaciones de estructuras tipo lista enlazada y *arrays* se ha comentado en clase, por lo que no consideramos necesaria su inserción en este documento.

### 3.4 Tiempos de ejecución

Para simplificar las pruebas y hacer más claro qué archivos contienen más datos, hemos decidido renombrar los archivos como A0, A1,..., A6 siendo A6.txt el más grande (*datosUniversidad99*) y A0.txt el archivo de pruebas más pequeño (*Extracto de datos para hacer pruebas*).

Todos los tiempos se tomaron en una máquina con procesador Intel i7 a 2.67 Ghz sobre arquitectura x86\_64, 6 GB de memoria RAM, bajo el S.O. Windows 7. Se ejecutaron todas las instrucciones diez veces y en la tabla se ha plasmado el valor medio de estas mediciones.

	<b>Sentencias de sujeto determinado</b>	<b>Sentencias distintas de sujeto determinado</b>	<b>Propiedades distintas del almacén</b>	<b>Entidades que son sujeto y objeto</b>	<b>Constructora del almacén</b>
<b>A0.txt</b>	0.071299 ms	0.042181 ms	0.000919 ms	0.018083 ms	21.355142 ms
<b>A1.txt</b>	0.048005 ms	0.043867 ms	0.000804 ms	0.087735 ms	34.169811 ms
<b>A2.txt</b>	0.024366 ms	0.021148 ms	0.000459 ms	0.67529 ms	75.093962 ms
<b>A3.txt</b>	0.025592 ms	0.022106 ms	0.000536 ms	1.285565 ms	1381.1628 ms
<b>A4.txt</b>	0.034634 ms	0.022604 ms	0.000498 ms	1.881511 ms	4022.8261 ms
<b>A5.txt</b>	0.021569 ms	0.018543 ms	0.000536 ms	2.811501 ms	12055.41 ms
<b>A6.txt</b>	0.006053 ms	0.003371 ms	0.000344 ms	6.106348 ms	52886.36 ms

Nota: el sujeto utilizado como argumento de los dos primeros métodos fue [<http://swat.cse.lehigh.edu/onto/univ-bench.owl#AdministrativeStaff>](http://swat.cse.lehigh.edu/onto/univ-bench.owl#AdministrativeStaff)

## 4. Versión 1

*Según vayamos avanzando en el curso y vayamos conociendo nuevas formas de estructurar los datos y nuevos modos de tratar esas estructuras, descubriremos que la Versión 0, realizada como primera opción, es mejorable con la aplicación de esos nuevos conocimientos.*

*Aprovecharemos todo lo que se pueda de la versión anterior (y no habrá que presentarlo en esta nueva sección, bastará con indicarlo). Con cada nueva versión, se explicarán y se justificarán los cambios fundamentales en las estructuras de datos y los métodos correspondientes.*

*Se mantendrá el estilo de la presentación: descripción y justificación de la representación de los datos, enumeración y especificación de cada método, análisis de eficiencia y tablas de tiempos de ejecución de los más relevantes.*

### 4.1 Cambios en la estructura

En primer lugar, la modificación más evidente y que no se llevó a cabo en la versión 0 por falta de tiempo ha sido en la implementación del trie. El atributo de cada nodo del árbol que contiene los punteros a los nodos hijos pasa de ser un array estático de 128 posiciones a una lista enlazada. Las ventajas de este cambio son evidentes: se aprovecha mucho mejor el espacio (dado el formato de las sentencias, muchas veces los nodos sólo tienen un hijo) y se puede usar cualquier carácter Unicode. La búsqueda de un nodo hijo se vuelve más lenta, pero en muchos casos es un tiempo despreciable debido al motivo antes expuesto: muchos nodos con un único hijo.

El segundo cambio importante se ha dado en la estructura de lista enlazada. Con vistas a la implementación del método de devolver sentencias en orden lexicográfico, se adapta la lista enlazada para que se puedan insertar elementos según un orden establecido mediante el método *compareTo* de la interfaz *Comparable<T>*. Este cambio se aplica en las listas enlazadas que contienen las listas de adyacencia.

Sin embargo, la pérdida de rendimiento con esta nueva estructura es notable, pues insertar un elemento en la lista ya no es una operación en tiempo constante, sino lineal.

Tras estudiar las posibilidades, se ha optado por convertir los elementos de las listas de adyacencia en listas de *arrays* estáticos, que permiten insertar elementos en orden en tiempo logarítmico gracias a la búsqueda dicotómica. Esto conlleva rescribir la estructura *ListaArray* para hacerla más flexible: como se desconoce el tamaño máximo que puede llegar a tener la lista, en caso de querer insertar un elemento en

una lista llena, se amplía su tamaño máximo creando un nuevo array más grande y copiando los elementos del array viejo en el nuevo. El impacto en rendimiento de esta funcionalidad pasa desapercibido pues el nuevo algoritmo de ordenación mejora mucho el anterior.

## 4.2 Nuevos métodos

## 5. Versión 2

*Es más que probable que convenga modificar las estructuras de datos más de una vez, ya que vamos a ir descubriendo estructuras interesantes durante todo el curso. Si se encuentra algo mejor, se valorará su incorporación a la aplicación. La finalidad del proyecto de programación es demostrar que se conocen las distintas estructuras de datos que iremos viendo en el curso y que se saben usar allá donde conviene para conseguir aplicaciones eficientes.*

*En cada sección, dedicada al efecto, se explicarán las razones de la correspondiente modificación. El código fuente se presentará, agrupado, en la correspondiente sección de anexos.*

## 6. Actas de las reuniones

*En esta sección se irán redactando, en orden cronológico y “en tiempo real”, las actas de las reuniones del grupo de trabajo. La periodicidad y el número de reuniones será una decisión del grupo de trabajo; pero parece razonable que, al menos, haya una cada semana. Cada acta llevará la fecha de realización y duración de la reunión. Cada acta tendrá una redacción breve; me extrañaría que fuese necesario superar la media página.*

*En estas actas deben reflejarse las decisiones tomadas en cada reunión y deben reflejarse los hitos relevantes del proyecto. Por ejemplo, deberá reflejarse el reparto de tareas entre las personas del grupo decidido para un objetivo concreto y, cuando sea el caso, reflejará los objetivos que se han conseguido al terminar determinada tarea. De este modo se puede tener un seguimiento del proceso de desarrollo del proyecto. Para ello es primordial que esas actas se redacten en el momento correspondiente y no se demore nunca su redacción más allá del comienzo de la siguiente reunión. Las decisiones de reparto de las tareas pueden ser fundamentales para un eficiente desarrollo del proyecto. Por ejemplo, mientras alguien realiza la implementación de unos métodos, otra persona puede realizar los métodos de prueba de los mismos y una tercera redactar las secciones correspondientes para la memoria. Puede ser interesante que, después, cada cual revise algún aspecto crítico de la tarea realizada por otro miembro del grupo, para asegurar la corrección de la misma. Este modo de actuar puede ser mucho más eficiente que el intento de realizar todos y a la vez. El modo de trabajo se verá reflejado en las actas de las reuniones.*

### **28 de septiembre**

Este día nos hemos reunido por primera vez en grupo para acordar como vamos a abordar el proyecto de EDA. Hemos discutido las diferentes ideas que han surgido entre los participantes del grupo y hemos decidimos recoger las ideas principales y desarrollarlas con más profundidad. Tras varias deliberaciones, hemos llegamos a una idea inicial de la estructura que vamos a implementar para realizar el proyecto. Esta avanzada estructura nos permitirá realizar las funciones deseadas en menor tiempo y con más eficacia, aunque el coste de implementarlas será mayor.

### **1 de octubre**

En esta segunda reunión hemos decidido varios aspectos a tener en cuenta y nos hemos repartido la tarea en varias partes:

- Hemos terminado de debatir las estructuras que vamos a utilizar en el proyecto.
- A cada miembro del grupo se le ha asignado un tipo de tarea a realizar:
  - Asier realizará la implementación del árbol necesario para la carga del fichero y construcción del grafo.



- Iván realizará las funciones respecto a la lectura/escritura del fichero.
- Daniel probará casos de prueba para las funciones creadas anteriormente por Asier e Iván, y realizará la parte de la memoria correspondiente a los primeros pasos del proyecto.

Conclusión del acta: Tras un día de trabajo en clase, se han completado con éxito todas las expectativas. En la siguiente reunión grupal se decidirán los nuevos trabajos a cada miembro del grupo.

### **3 de octubre**

En esta tercera reunión hemos decidido algunas nuevas ideas para modificar y mejorar el proyecto:

- La estructura para hacer los ejercicios que se decidió en la primera reunión ha resultado ser inválida. Por lo que hemos decidido una nueva manera de implementación, tal y como se refleja detalladamente en el apartado *Versión 0* de la memoria.

### **5 de octubre**

Considerando los puntos a mejorar ressaltados durante la primera evaluación con el profesor, en esta cuarta reunión hemos decidido repartir el trabajo a cada miembro del grupo rotando los papeles para que todos participemos por igual:

- Ivan aclarará el código del proyecto para una mejor comprensión de las estructuras y hacer el código más legible.
- Daniel realizará algunos cambios en los algoritmos para adaptarlos al enunciado del proyecto. También realizará el análisis de complejidad de algunos de los métodos implementados.
- Asier efectuará los pertinentes cambios a la memoria acorde al seguimiento del proyecto y culminará el análisis de los algoritmos.

## **7. Anexos**

### ***Anexo versión 0***

*Código fuente de lo implementado para la versión 0:*

<https://github.com/Sulley38/ProyectoEDA/raw/master/Version0.zip>

### ***Anexo versión 1***

*Código fuente de lo implementado para la versión 1.*

### ***Anexo versión 2***

*Código fuente de lo implementado para la versión 2.*